Factores de riesgo cardiovascular y predicción de enfermedad coronaria: un enfoque de ciencia de datos con regresión logística y árboles de decisión en pacientes remitidos a angiografía

Cardiovascular risk factors and prediction of coronary artery disease: a data science approach using logistic regression and decision trees in patients referred for angiography

Angie Milena Tobar Aguirre

Pregrado en Ciencia de Datos, Universidad Externado de Colombia
angie.tobar@est.uexternado.edu.co

Alejandro Pardo Costo

Pregrado en Ciencia de Datos, Universidad Externado de Colombia
alejandro.pardo2@est.uexternado.edu.co

RESUMEN

Antecedentes. La enfermedad coronaria (EC) es la principal causa de muerte en el mundo y su confirmación requiere angiografía, un procedimiento invasivo y costoso. **Objetivo.** Caracterizar los factores de riesgo cardiovascular y los hallazgos clínicos asociados a la EC angiográfica y evaluar la discriminación y calibración de modelos de regresión logística y árboles de decisión. **Métodos.** Estudio observacional analítico de corte transversal con la base oficial UCI *Heart Disease* (Cleveland; 303 pacientes; 297 con datos completos y 137 eventos). Se auditaron los datos, se estimaron OR por rangos clínicos y OR ajustados por regresión logística con verificación de supuestos, y se compararon una regresión logística básica (11 variables no invasivas), una extendida (con fluoroscopia y gammagrafía con talio), un árbol CART y un Random Forest mediante validación cruzada estratificada 5×20, bootstrap de optimismo, AUC con IC de DeLong y calibración. **Resultados.** Fueron predictores independientes el dolor torácico asintomático (OR 10,60; IC 95 % 3,17–35,40), el sexo masculino (OR 7,48; 3,25–17,20) y la depresión del ST (OR 1,82 por mm; 1,23–2,69); la frecuencia cardíaca máxima fue protectora con significancia limítrofe (OR 0,82 por 10 lpm; $p = 0{,}048$). El colesterol no se asoció de forma independiente. El modelo básico alcanzó un AUC de 0,874 (0,880 corregido por optimismo) con pendiente de calibración de 0,91; la imagen aportó un ΔAUC de 0,035 ($p = 0{,}012$). La regresión logística superó al árbol (ΔAUC 0,067; $p = 0{,}004$) e igualó al Random Forest. La versión de Kaggle de la base, usada en una fase previa, tenía la etiqueta diagnóstica invertida. **Conclusión.** Las variables clínicas de bajo costo discriminan bien la EC angiográfica; un modelo logístico simple y bien calibrado es preferible a algoritmos más complejos en esta población.

Palabras Clave: enfermedad coronaria; factores de riesgo cardiovascular; regresión logística; árboles de decisión; validación cruzada; calibración.

ABSTRACT

Coronary artery disease (CAD) is the leading cause of death worldwide and its confirmation requires invasive angiography. Using the official UCI *Heart Disease* Cleveland dataset (297 complete cases, 137 events), we estimated crude and adjusted odds ratios and compared a basic logistic regression (11 non-invasive variables), an extended model (adding fluoroscopy and thallium scintigraphy), a CART tree and a Random Forest through repeated stratified 5×20 cross-validation, optimism bootstrap, DeLong confidence intervals and calibration. Asymptomatic chest pain (OR 10.60), male sex (OR 7.48) and exercise ST depression (OR 1.82 per mm) were independent predictors. The basic model reached an AUC of 0.874 (0.880 optimism-corrected) with good calibration; imaging added 0.035. Logistic regression outperformed the tree and matched the Random Forest. The widely used Kaggle version of the dataset has an inverted diagnostic label.

Keywords: coronary artery disease; cardiovascular risk factors; logistic regression; decision trees; cross-validation; calibration.

1. Introducción

Las enfermedades cardiovasculares causaron 19,2 millones de muertes en 2023, una de cada tres en el mundo [1]. Se estiman unos 315 millones de casos prevalentes de EC [2], y en Colombia las cuatro enfermedades cardiovasculares más frecuentes afectan a 5,6 millones de personas [3]. Un evento coronario cuesta entre \$17 y \$29 millones COP según la

comorbilidad, y el costo cae más del 80 % después de la fase aguda [4].

La EC es el estrechamiento de las arterias coronarias por placa aterosclerótica. Su diagnóstico es escalonado: historia clínica, electrocardiograma (ECG), prueba de esfuerzo, imagen funcional y, finalmente, angiografía coronaria, que es el estándar de referencia [5]. Desde Diamond y Forrester se sabe que la edad, el sexo y el tipo de dolor torácico permiten estimar la probabilidad pretest de la enfermedad [6]. Detrano *et al.* desarrollaron con los datos de Cleveland un algoritmo de probabilidad aplicado en cuatro centros [7], y el CAD Consortium mostró que las reglas clásicas sobrestiman la prevalencia actual [8].

La base de Cleveland es una de las más usadas para enseñar clasificación, con exactitudes reportadas superiores al 90 % sobre particiones de unos 60 pacientes [9]. Sin embargo, persisten tres problemas: (i) evaluaciones con una sola partición pequeña, muy inestables; (ii) omisión de la calibración, que es indispensable para un uso clínico [10]; y (iii) mezcla de variables de consulta con variables de imagen, que impide saber cuánto discriminan por sí solas las variables de bajo costo. **Este estudio cubre ese vacío**: cuantifica el desempeño de las variables no invasivas y el valor incremental de la imagen con validación interna rigurosa, siguiendo TRIPOD [11].

Pregunta de investigación. En adultos remitidos a angiografía por sospecha clínica, ¿qué factores de riesgo y hallazgos no invasivos se asocian de forma independiente con la EC angiográfica, y con qué discriminación y calibración la predicen modelos de regresión logística y árboles de decisión, con y sin variables de imagen?

1.1 Problema y justificación

En la cohorte, 160 de 297 pacientes remitidos a angiografía (53,9 %) no tenían EC.

- **Causas:** síntomas atípicos o silentes (el 47,8 % era asintomático), información clínica dispersa y estimación subjetiva del riesgo.
- **Consecuencias:** procedimientos invasivos innecesarios, diagnósticos tardíos y uso ineficiente de la hemodinamia.
- **Alternativa:** integrar en un modelo validado las variables disponibles antes de la angiografía.
- **Beneficiarios:** pacientes y médicos (directos); IPS, EPS y sistema de salud (indirectos).

1.2 Objetivos

General. Caracterizar los factores de riesgo cardiovascular y los hallazgos clínicos asociados a la EC angiográfica en 297 pacientes remitidos a angiografía, y evaluar el desempeño predictivo (discriminación y calibración) de modelos de regresión logística y árboles de decisión.

Específicos.

OE1. Describir las características de la cohorte según la presencia de EC.

OE2. Determinar la asociación cruda (OR por rangos) y ajustada (regresión logística) de cada factor con la EC.

OE3. Desarrollar y validar internamente modelos de regresión logística, árbol de decisión y Random Forest, y evaluar su desempeño.

OE4. Cuantificar el valor incremental de la fluoroscopia y de la gammagrafía con talio.

OE5. Contrastar los resultados con la literatura.

1.3 Hipótesis

General: los factores de riesgo y los hallazgos de consulta, ECG y prueba de esfuerzo predicen la EC con un desempeño clínicamente aceptable. Se contrastan cuatro pares de hipótesis ($\alpha = 0{,}05$):

- **H-1** (OE2). H0: todos los $\beta_j = 0$ en el modelo básico. H1: al menos un $\beta_j \neq 0$.
- **H-2** (OE3). H0: $\mathrm{AUC}_{\text{básico}} \leq 0{,}80$. H1: $\mathrm{AUC}_{\text{básico}} > 0{,}80$.
- **H-3** (OE4). H0: $\mathrm{AUC}_{\text{ext}} = \mathrm{AUC}_{\text{básico}}$. H1: $\mathrm{AUC}_{\text{ext}} > \mathrm{AUC}_{\text{básico}}$.
- **H-4** (OE3). H0: $\mathrm{AUC}_{\text{CART}} = \mathrm{AUC}_{\text{RL ext}}$. H1: los AUC difieren.

2. Metodología

2.1 Diseño, población y muestra

- **Diseño:** estudio aplicado, cuantitativo, observacional analítico de corte transversal, con datos secundarios y desarrollo y validación interna de un modelo diagnóstico (TRIPOD tipo 1b [11]).
- **Universo:** adultos con sospecha de EC.
- **Población:** pacientes remitidos a angiografía en la Cleveland Clinic Foundation (Ohio, EE. UU.), con datos donados a UCI en 1988 [7; 12].
- **Unidad de análisis:** el paciente.

- **Muestreo:** censo de los 303 registros, que corresponden a pacientes consecutivos (no probabilístico).
- **Inclusión:** angiografía y 13 predictores completos. **Exclusión:** faltantes en `ca` ($n = 4$) o en `thal` ($n = 2$). Muestra analítica: $n = 297$ (Fig. 1).
- **Desenlace:** EC angiográfica, es decir, estenosis $>$ 50 % en al menos un vaso mayor (`num` ≥ 1).

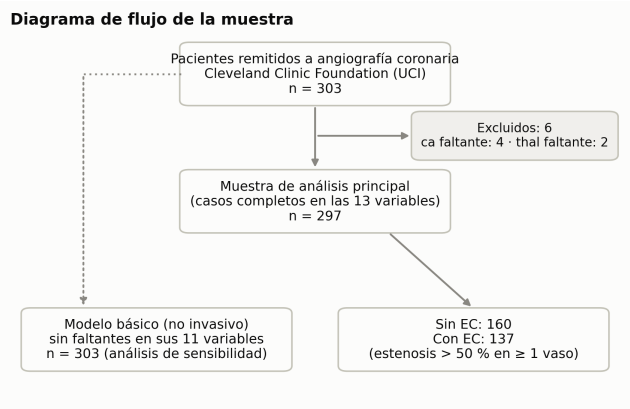


Fig. 1. Diagrama de flujo de la muestra. La línea punteada indica el análisis de sensibilidad con $n = 303$.

Tamaño de muestra. Según los criterios de Riley *et al.* [13] (contracción $\geq 0{,}90$; optimismo del $R^2 \leq 0{,}05$; prevalencia $\pm 0{,}05$), se requerían $n = 412$ para el modelo básico (14 parámetros) y $n = 382$ para el extendido (17). Con $n = 297$ hay 9,8 y 8,1 eventos por parámetro. Se declara como limitación y se mitiga con penalización L2, validación cruzada repetida, corrección de optimismo y reporte de la pendiente de calibración.

2.2 Variables

- **Factores de riesgo:** edad, sexo, presión arterial sistólica en reposo (PAS), colesterol total y glucemia en ayunas $>$ 120 mg/dL.
- **Marcadores clínicos:** tipo de dolor torácico, ECG de reposo (colapsado a normal/anormal porque la anomalía ST-T tiene $n = 4$), frecuencia cardíaca (FC) máxima, angina de esfuerzo, depresión del ST y pendiente del ST.
- **Imagen:** vasos coloreados por fluoroscopia (`ca`) y gammagrafía con talio (`thal`).

La definición conceptual y operacional de cada variable está en el anexo del repositorio (`docs/diccionario_variables.md`).

2.3 Control de calidad de los datos

Se usó el archivo oficial `processed.cleveland.data`, verificado por SHA-256, y se aplicaron controles de rango fisiológico, de códigos válidos y de duplicados: no se encontró ningún valor fuera de rango, ningún código inválido ni ningún duplicado. Además se auditó la versión de Kaggle usada en la fase previa del proyecto, emparejando registro a registro:

- la etiqueta `target` está **invertida en el 100 % de los casos**;
- `cp`, `restecg` y `slope` están recodificadas;
- hay faltantes ocultos como `ca` $= 4$ y `thal` $= 0$;
- hay un registro duplicado (Fig. 2).

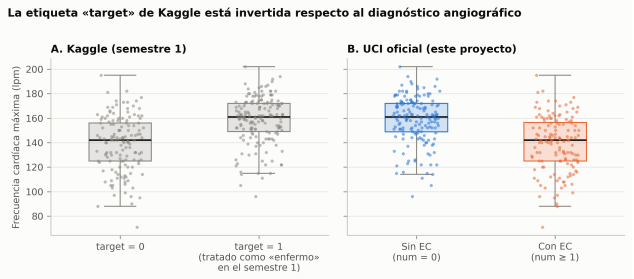


Fig. 2. FC máxima según la etiqueta de Kaggle (A) y la oficial (B). Con la etiqueta oficial, los pacientes con EC alcanzan menor FC, como se espera fisiológicamente.

2.4 Análisis estadístico

Descriptivo. Se evaluó la normalidad con Shapiro-Wilk [14] en cada grupo. Las continuas se compararon con U de Mann-Whitney (correlación biserial por rangos) o t de Welch, y las cualitativas con χ^2 de Pearson (V de Cramér), exacta de Fisher o χ^2 por Monte Carlo cuando algún esperado era < 5.

Paso preliminar. Según el tipo de variable dependiente (Y continua: regresión lineal; Y binaria: logística), se ajustaron dos modelos de mínimos cuadrados: un modelo lineal de probabilidad (MLP) sobre la EC y una regresión de la PAS sobre la edad, el sexo, el colesterol y la glucemia. Sus supuestos se verificaron con Shapiro-Wilk sobre los residuos y con Breusch-Pagan.

Asociación.

- **OR por rangos** con cortes clínicos fijados de antemano: OR $= ad/bc$, con IC de Woolf.
- **Regresión logística** por máxima verosimilitud sin penalizar: OR crudos y ajustados (modelos básico y ex-

tendido), con IC de Wald.

- **Supuestos:** linealidad del logit (Box-Tidwell), colinealidad (VIF), bondad de ajuste (Hosmer-Lemeshow [15]) e influencia (distancia de Cook).

Modelos predictivos (scikit-learn [16]):

M0. Regresión logística (RL) con 4 variables continuas, como línea base de la fase previa.

M1. RL básica (11 variables no invasivas).

M2. RL extendida (13 variables). En M0–M2: penalización L2, $C = 1$, variables estandarizadas.

M3. Árbol CART con criterio de Gini [17]; profundidad $\in \{2,\ldots,5\}$ y tamaño mínimo de hoja $\in \{5,10,20\}$, elegidos por validación cruzada anidada.

M4. Random Forest [18] con 300 árboles y hojas de al menos 5 pacientes.

Validación.

- Validación cruzada estratificada repetida 5×20, con las mismas 100 particiones para todos los modelos.
- Bootstrap de optimismo de Harrell con 500 réplicas [19].
- AUC con IC de DeLong [20; 21].
- Calibración: pendiente, intercepto y Brier [10].
- Sensibilidad, especificidad, VPP y VPN con umbral 0,5 y con el umbral que garantiza una sensibilidad $\geq$ 90 %.
- Comparaciones pareadas con la *t* corregida de Nadeau-Bengio [22] y con DeLong.

Herramientas y reproducibilidad. Python 3.12 (pandas, SciPy, statsmodels [23], scikit-learn y matplotlib) en notebooks ejecutables, con semilla fija y versiones fijadas. El comando `make verify` reproduce todos los resultados de forma idéntica. Repositorio: `https://github.com/AlejandroP212/Proyecto_Final_Healtech1`.

2.5 Consideraciones éticas

Es una investigación sin riesgo según la Resolución 8430 de 1993, art. 11 [24]: usa datos secundarios públicos y anonimizados (licencia CC BY 4.0), por lo que no requiere consentimiento informado. No se procesan datos personales identificables (Ley 1581 de 2012 [25]).

3. Resultados

3.1 Características de la cohorte

De los 297 pacientes, 137 (46,1 %) tenían EC. Ninguna variable continua fue normal en ambos grupos, por lo que todas se compararon con Mann-Whitney. Los pacientes con EC eran mayores, más frecuentemente hombres y asintomáticos; alcanzaron menor FC máxima, y presentaron más depresión del ST, más angina de esfuerzo y más hallazgos anormales de imagen (Tabla 1). Solo la glucemia en ayunas no difirió entre grupos.

3.2 Paso preliminar: regresión lineal

- **MLP:** $R^2 = 0{,}47$, pero **43 de 297 predicciones cayeron fuera de [0, 1]** (de $-0{,}31$ a 1,19), con heterocedasticidad (Breusch-Pagan $p = 0{,}003$).
- **Modelo de la PAS:** $R^2 = 0{,}11$; residuos no normales (Shapiro-Wilk $p = 0{,}004$) y heterocedásticos (Breusch-Pagan $p = 0{,}016$), con varianza residual mayor en los pacientes de 55 años o más (338 frente a 212 mmHg^2).

Ambos modelos se rechazaron (Fig. 3), lo que justifica la regresión logística.

3.3 Factores asociados (H-1)

En el análisis por rangos, los marcadores de esfuerzo fueron los de mayor riesgo crudo: depresión del ST $\geq$ 1 mm (OR 5,06; 3,08–8,29) y FC máxima $<$ 85 % de la esperada (OR 4,88; 2,83–8,39). También fueron significativas la edad $\geq$ 55 años (OR 3,39) y la PAS $\geq$ 140 mmHg (OR 1,72). El colesterol $\geq$ 240 mg/dL no lo fue (OR 1,51; 0,95–2,38) (Tabla 2).

Tabla. 2. OR crudos por rangos clínicos (tablas 2×2, IC 95 % de Woolf).

Rango (expuesto)	OR (IC 95 %)	*p*
Edad $\geq$ 55 años	3,39 (2,10–5,49)	$<$ 0,001
PAS $\geq$ 140 mmHg	1,72 (1,05–2,79)	0,029
Colesterol $\geq$ 240 mg/dL	1,51 (0,95–2,38)	0,080
FC máx. $<$ 85 % de la esperada	4,88 (2,83–8,39)	$<$ 0,001
Depresión del ST $\geq$ 1 mm	5,06 (3,08–8,29)	$<$ 0,001
FC máx. $\leq$ 162 lpm[a]	4,67 (2,65–8,23)	$<$ 0,001

[a]Corte de la fase previa; con la etiqueta invertida se había concluido lo contrario.

En el modelo multivariable básico se rechazó H0 de H-1 (razón de verosimilitud $\chi^2 = 174{,}7$; gl = 14; $p < 0{,}001$; R^2 de Nagelkerke = 0,594). Los supuestos se cumplieron: Box-Tidwell con $p \geq 0{,}22$, VIF $\leq 4{,}2$ y Hosmer-Lemeshow

Tabla. 1. Características de la cohorte según diagnóstico angiográfico ($n = 297$). Continuas: mediana [RIC]; cualitativas: n (%).

Variable	**Categoría**	**Total**	**Sin EC** ($n = 160$)	**Con EC** ($n = 137$)	**Prueba**	p
Edad (años)		56 [48–61]	52 [44,8–59]	58 [53–62]	Mann-Whitney	$< 0{,}001$
PAS en reposo (mmHg)		130 [120–140]	130 [120–140]	130 [120–145]	Mann-Whitney	0,023
Colesterol (mg/dL)		243 [211–276]	235,5 [208,8–268,2]	253 [218–284]	Mann-Whitney	0,047
FC máxima (lpm)		153 [133–166]	161 [149–172]	142 [125–157]	Mann-Whitney	$< 0{,}001$
Depresión del ST (mm)		0,8 [0–1,6]	0,2 [0–1,1]	1,4 [0,6–2,5]	Mann-Whitney	$< 0{,}001$
Vasos por fluoroscopia (0–3)		0 [0–1]	0 [0–0]	1 [0–2]	Mann-Whitney	$< 0{,}001$
Sexo	Hombre	201 (67,7)	89 (55,6)	112 (81,8)	χ^2	$< 0{,}001$
Glucemia > 120 mg/dL	Sí	43 (14,5)	23 (14,4)	20 (14,6)	χ^2	0,956
Angina de esfuerzo	Sí	97 (32,7)	23 (14,4)	74 (54,0)	χ^2	$< 0{,}001$
Dolor torácico	Angina típica	23 (7,7)	16 (10,0)	7 (5,1)	χ^2	$< 0{,}001$
	Angina atípica	49 (16,5)	40 (25,0)	9 (6,6)		
	No anginoso	83 (27,9)	65 (40,6)	18 (13,1)		
	Asintomático	142 (47,8)	39 (24,4)	103 (75,2)		
ECG en reposo	Normal	147 (49,5)	92 (57,5)	55 (40,1)	χ^2 (Monte Carlo)	0,005
	Anomalía ST-T	4 (1,3)	1 (0,6)	3 (2,2)		
	Hipertrofia VI	146 (49,2)	67 (41,9)	79 (57,7)		
Pendiente del ST	Ascendente	139 (46,8)	103 (64,4)	36 (26,3)	χ^2	$< 0{,}001$
	Plana	137 (46,1)	48 (30,0)	89 (65,0)		
	Descendente	21 (7,1)	9 (5,6)	12 (8,8)		
Gammagrafía con talio	Normal	164 (55,2)	127 (79,4)	37 (27,0)	χ^2	$< 0{,}001$
	Defecto fijo	18 (6,1)	6 (3,8)	12 (8,8)		
	Defecto reversible	115 (38,7)	27 (16,9)	88 (64,2)		

con $p = 0{,}53$. Los predictores independientes fueron el dolor asintomático, el sexo masculino y la depresión del ST; la FC máxima fue protectora pero limítrofe, con $p = 0{,}048$ en el modelo principal y $p = 0{,}051$ en el análisis de sensibilidad con $n = 303$ (Tabla 3, Fig. 4). La edad, la angina de esfuerzo y la pendiente del ST perdieron significancia al ajustar. En el modelo extendido dominaron el número de vasos (OR 3,71 por vaso) y el defecto reversible en la gammagrafía con talio (OR 4,03).

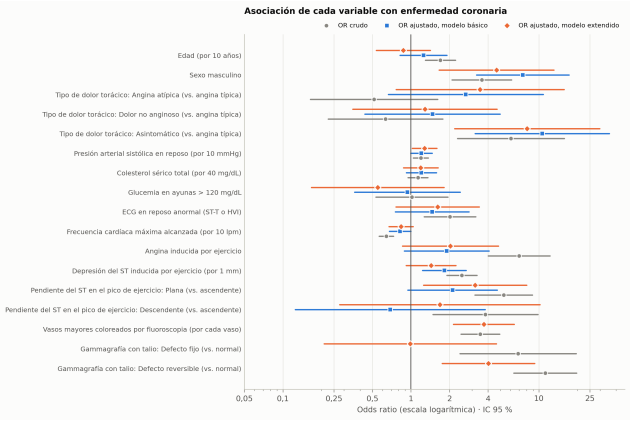


Fig. 4. OR crudos (gris) y ajustados en los modelos básico (azul) y extendido (naranja), en escala logarítmica.

3.4 Desempeño predictivo (H-2 a H-4)

El modelo básico alcanzó un AUC de 0,874 en validación cruzada, con IC de DeLong de 0,836 a 0,914 y un AUC de 0,880 corregido por optimismo (optimismo de 0,021). Por tanto, se rechaza H0 de H-2. Su pendiente de calibración fue de 0,91 (Tabla 4, Figs. 5 y 6). La imagen aumentó el AUC en 0,035 (IC 95 % 0,008–0,062; $p = 0{,}012$), y se rechaza H0 de H-3. La RL extendida superó al árbol (ΔAUC 0,067; IC 0,021–0,113; $p = 0{,}004$), y se rechaza H0 de H-4. No difirió del Random Forest (ΔAUC $-0{,}001$; $p = 0{,}94$). El árbol estuvo sobreajustado (pendiente de calibración de 0,26) y fue inestable: sus hiperparámetros modales (profundidad 4, hojas de al menos 10 pacientes) se eligieron solo en el 32 % de las particiones. Con 4 variables (M0), el AUC fue de 0,749, de modo que M1 lo mejoró en 0,125 ($p < 0{,}001$).

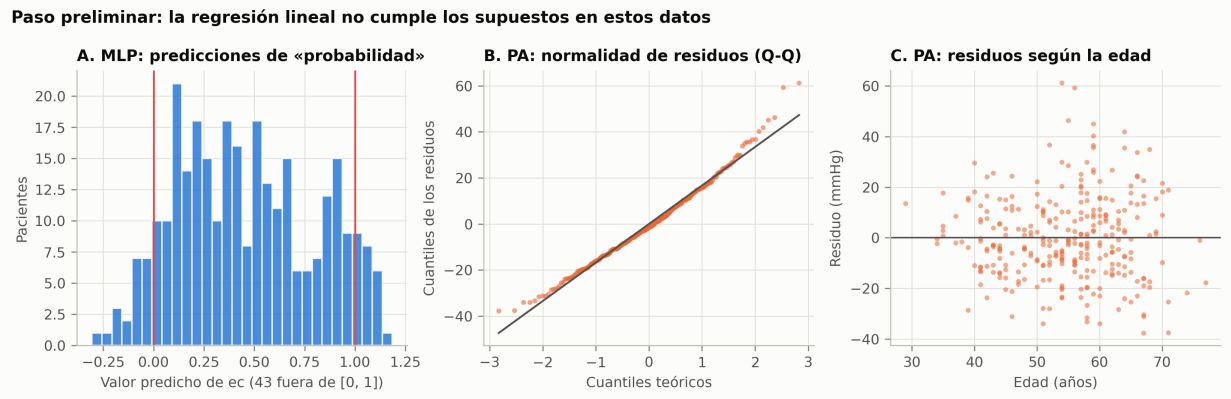


Fig. 3. Paso preliminar. (A) El MLP predice "probabilidades" fuera de $[0, 1]$. (B) Gráfico Q-Q de los residuos del modelo de la PAS. (C) Residuos de la PAS según la edad: la dispersión crece con la edad.

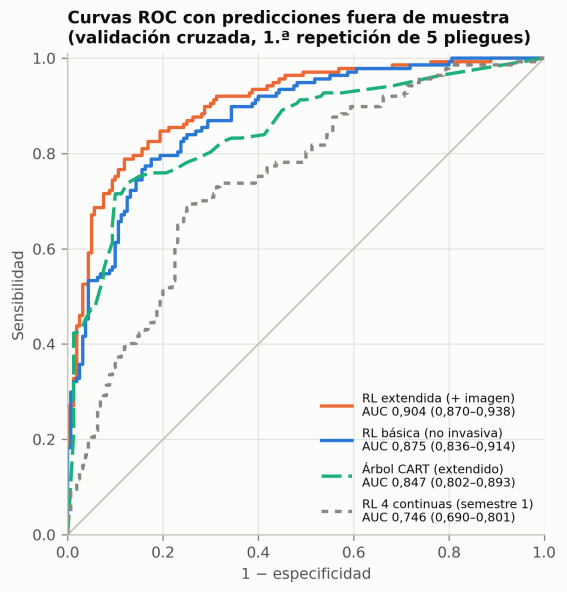


Fig. 5. Curvas ROC con predicciones fuera de muestra.

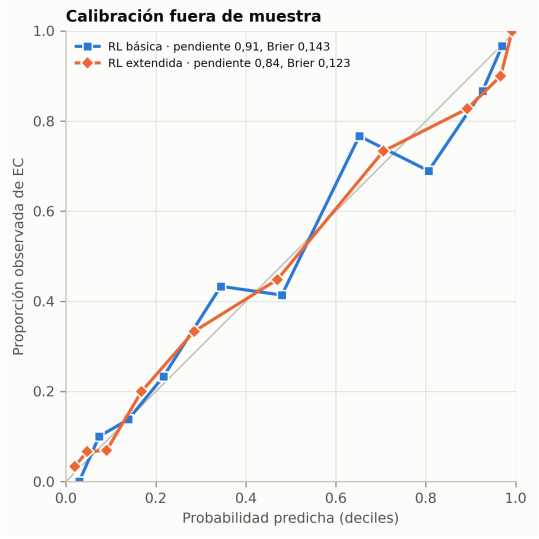


Fig. 6. Calibración fuera de muestra (deciles de riesgo).

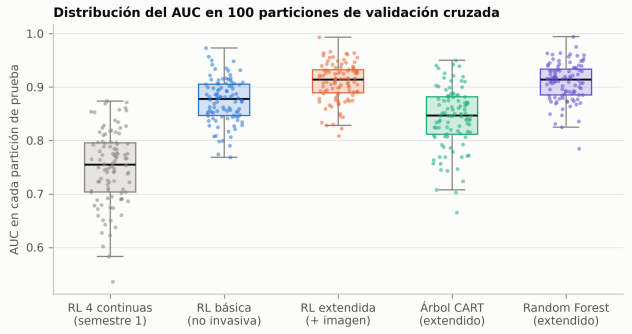


Fig. 7. AUC en cada una de las 100 particiones: una sola partición puede dar resultados muy distintos.

Tabla. 3. OR crudos y ajustados (regresión logística por máxima verosimilitud). Referencias: angina típica, pendiente ascendente y talio normal.

Variable	OR crudo (IC 95 %)	p	OR ajustado básico	p	OR ajustado extendido	p
Edad (por 10 años)	1,70 (1,29–2,23)	$< 0{,}001$	1,25 (0,82–1,91)	0,294	0,87 (0,54–1,42)	0,580
Sexo masculino	3,57 (2,10–6,10)	$< 0{,}001$	**7,48 (3,25–17,20)**	$< 0{,}001$	4,66 (1,66–13,08)	0,003
Dolor: angina atípica	0,51 (0,16–1,62)	0,255	2,68 (0,66–10,81)	0,166	3,47 (0,77–15,69)	0,107
Dolor: no anginoso	0,63 (0,23–1,77)	0,384	1,47 (0,44–4,96)	0,533	1,28 (0,35–4,71)	0,705
Dolor: asintomático	6,04 (2,31–15,79)	$< 0{,}001$	**10,60 (3,17–35,40)**	$< 0{,}001$	8,08 (2,19–29,83)	0,002
PAS (por 10 mmHg)	1,19 (1,05–1,36)	0,009	1,21 (0,99–1,47)	0,059	1,28 (1,02–1,59)	0,029
Colesterol (por 40 mg/dL)	1,13 (0,95–1,36)	0,170	1,21 (0,92–1,58)	0,175	1,19 (0,87–1,63)	0,268
Glucemia > 120 mg/dL	1,02 (0,53–1,95)	0,956	0,94 (0,36–2,42)	0,894	0,55 (0,17–1,81)	0,325
ECG de reposo anormal	2,02 (1,27–3,21)	0,003	1,46 (0,75–2,84)	0,259	1,61 (0,76–3,41)	0,210
FC máxima (por 10 lpm)	0,64 (0,56–0,73)	$< 0{,}001$	**0,82 (0,68–1,00)**	0,048	0,84 (0,67–1,04)	0,107
Angina de esfuerzo	7,00 (4,02–12,19)	$< 0{,}001$	1,90 (0,89–4,07)	0,098	2,03 (0,86–4,82)	0,107
Depresión del ST (por mm)	2,50 (1,91–3,28)	$< 0{,}001$	**1,82 (1,23–2,69)**	0,003	1,43 (0,92–2,25)	0,115
Pendiente del ST plana	5,30 (3,16–8,90)	$< 0{,}001$	2,11 (0,95–4,72)	0,068	3,17 (1,25–8,02)	0,015
Pendiente del ST descendente	3,81 (1,48–9,80)	0,005	0,69 (0,12–3,80)	0,668	1,68 (0,28–10,19)	0,572
Vasos por fluoroscopia (por vaso)	3,48 (2,46–4,93)	$< 0{,}001$	—	—	3,71 (2,15–6,41)	$< 0{,}001$
Talio: defecto fijo	6,86 (2,41–19,54)	$< 0{,}001$	—	—	0,99 (0,21–4,64)	0,987
Talio: defecto reversible	11,19 (6,35–19,70)	$< 0{,}001$	—	—	4,03 (1,75–9,27)	0,001

Tabla. 4. Desempeño en validación cruzada 5×20 (media y percentiles 2,5–97,5) y con predicciones fuera de muestra.

Modelo	AUC CV	AUC (IC DeLong)	Brier	Pend. calib.	Sens./Esp. (0,5)	Esp. (sens. $\geq$90 %)
M0 RL 4 continuas	0,749 (0,612–0,865)	0,746 (0,690–0,801)	0,205	0,93	0,650 / 0,769	0,344
M1 RL básica	**0,874 (0,794–0,949)**	**0,875 (0,836–0,914)**	0,146	**0,91**	0,752 / 0,844	0,613
M2 RL extendida	0,909 (0,829–0,964)	0,904 (0,870–0,938)	0,120	0,84	0,788 / 0,875	0,700
M3 Árbol CART	0,842 (0,715–0,940)	0,847 (0,802–0,893)	0,163	0,26	0,737 / 0,875	0,519
M4 Random Forest	0,910 (0,833–0,964)	0,905 (0,872–0,938)	0,127	1,59	0,759 / 0,875	0,719

Con el umbral que garantiza una sensibilidad del 90 % (0,24), el modelo básico detectó 124 de 137 enfermos y descartó correctamente a 98 de 160 sanos (especificidad del 61,3 %; VPN del 88,3 %).

4. Discusión

Con información obtenible sin imagen, un modelo logístico discrimina la EC con un AUC de 0,87–0,88 y buena calibración. La imagen aporta poco, y el modelo simple iguala al complejo.

Coherencia con la literatura. El dolor torácico y el sexo son los pilares de las reglas de probabilidad pretest [6; 8]. La asociación inversa de la FC máxima es fisiológica: el miocardio isquémico limita la respuesta cronotrópica (incompetencia cronotrópica, OR 4,88). La depresión del ST es el marcador clásico de isquemia de esfuerzo [5].

El colesterol. Su falta de asociación se explica por tres razones: (i) el colesterol actúa durante décadas, mientras los marcadores de esfuerzo reflejan la enfermedad ya instaurada; (ii) en una cohorte remitida ambos grupos tienen perfiles de riesgo elevados (sesgo de espectro); y (iii) se desconoce el uso de estatinas. Esto no resta importancia al colesterol en la prevención.

Comparación con Chandrasekhar y Peddakrishna [9]. Ellos reportaron una exactitud del 90,2 % y una sensibilidad del 100 % para la RL con 61 pacientes de prueba. Nuestras métricas son menores pero más robustas: la Fig. 7 muestra que el AUC del mismo modelo varía entre 0,83 y 0,96 según la partición, y nosotros reportamos IC, calibración y corrección de optimismo. Ambos estudios coinciden en que la RL es competitiva frente a algoritmos más complejos.

Calidad de los datos. La etiqueta invertida de la versión de Kaggle había llevado, en la fase previa del proyecto, a concluir que una FC alta era un factor de riesgo. Verificar la fuente cambió las conclusiones, lo que confirma que el control de calidad es parte del método.

Limitaciones.

- Datos de EE. UU. de los años 80, de pacientes remiti-

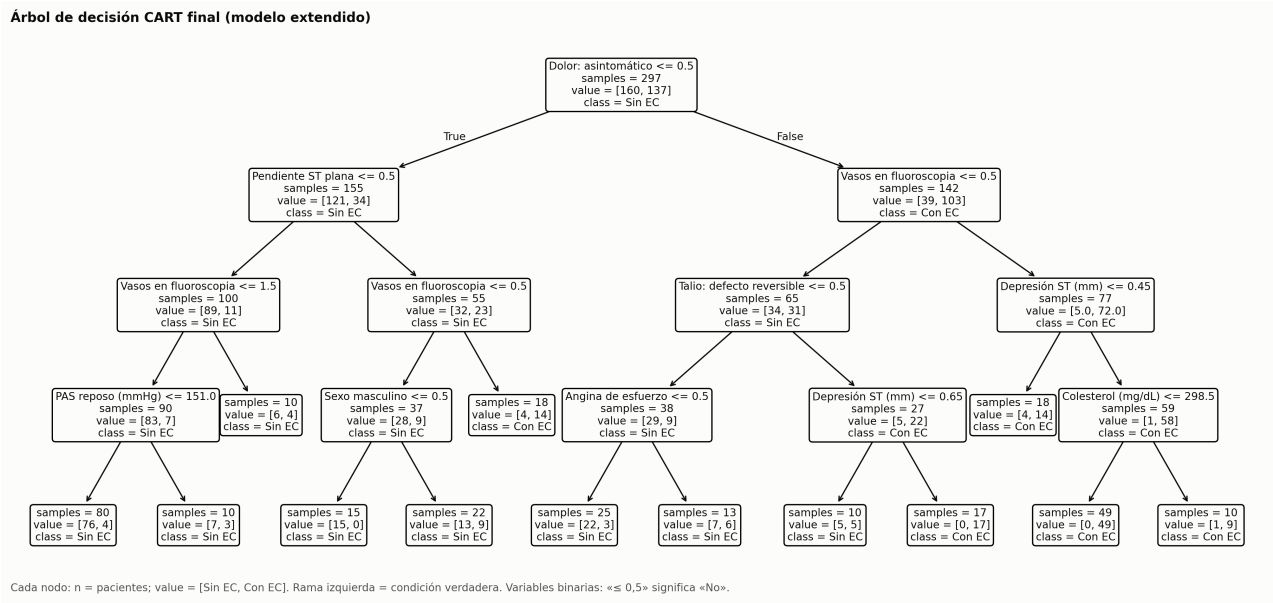


Fig. 8. Árbol CART final. La primera división es el dolor torácico asintomático; le siguen el número de vasos, el talio con defecto reversible y la pendiente del ST.

dos (sesgo de espectro).

- Tamaño de muestra menor que el recomendado y predominio masculino (67,7 %).
- Ausencia de tabaquismo, diabetes diagnosticada, IMC y estatinas.
- Diseño transversal y validación solo interna.

Se mitigaron con penalización, validación repetida, corrección de optimismo, análisis de sensibilidad y reporte de la calibración. El modelo no debe usarse clínicamente sin validación externa.

Trabajo futuro. Validación externa con las sedes de Hungría, Suiza y Long Beach, y con datos colombianos (con aval ético); incorporación de factores ausentes; y análisis de curva de decisión.

5. Conclusiones

1. El sexo masculino, el dolor torácico asintomático y la depresión del ST se asocian de forma independiente con la EC angiográfica. La FC máxima alta es protectora, con evidencia limítrofe, y el colesterol no se asoció.
2. Un modelo logístico con 11 variables no invasivas discrimina bien (AUC de 0,874; 0,880 corregido) y está bien calibrado.
3. La fluoroscopia y la gammagrafía con talio mejoran la discriminación de forma significativa pero modesta (+0,035).
4. La RL supera al árbol de decisión e iguala al Random Forest, con mejor calibración e interpretabilidad.
5. La versión de Kaggle de esta base tiene la etiqueta invertida: verificar la fuente de los datos es indispensable.

6. Administración del proyecto

Equipo. Angie Tobar y Alejandro Pardo (coinvestigadores), con la asesoría metodológica de la Prof. Eliana Andrea González Artunduaga.

Instituciones. Universidad Externado de Colombia (ejecutora), UCI Machine Learning Repository (proveedor de los datos) y Cleveland Clinic Foundation (origen de los datos).

Cronograma.

- **Semestre 1 (feb–may 2026):** selección de la base, exploración, primeros modelos y presentación.
- **Semestre 2 (ago–nov 2026):** ficha de la base; estructura del proyecto; auditoría y migración a la base oficial; reanálisis; documento final; exposición (3–14 nov).

Presupuesto (referencial). El costo total estimado es de $8.977.500 COP:

- personal: 2 investigadores $\times$ 120 h, $6.000.000;
- asesoría: 20 h, $1.800.000;
- equipos: $400.000;
- datos y software libres: $0;
- divulgación: $150.000;
- administrativos: $200.000;
- imprevistos (5 %): $427.500.

El 94 % es aporte en especie y contrapartida institucional, sin financiación externa.

BIBLIOGRAFÍA

[1] Institute for Health Metrics and Evaluation. Cardiovascular diseases caused 1 in 3 global deaths in 2023. Seattle: IHME; 2025.

[2] Stark B, Johnson C, Roth GA. Global prevalence of coronary artery disease: an update from the Global Burden of Disease Study. J Am Coll Cardiol. 2024;83(13 Suppl):2320.

[3] Deloitte; Revista Semana. El costo de las enfermedades del corazón en Colombia. Bogotá; 2015.

[4] Revista Colombiana de Cardiología. Estimación de los costos directos de los eventos coronarios en Colombia. Rev Colomb Cardiol. 2018.

[5] Vrints C, Andreotti F, Koskinas KC, Rossello X, Adamo M, Ainslie J, et al. 2024 ESC Guidelines for the management of chronic coronary syndromes. Eur Heart J. 2024;45(36):3415-537.

[6] Diamond GA, Forrester JS. Analysis of probability as an aid in the clinical diagnosis of coronary-artery disease. N Engl J Med. 1979;300(24):1350-8.

[7] Detrano R, Janosi A, Steinbrunn W, Pfisterer M, Schmid JJ, Sandhu S, et al. International application of a new probability algorithm for the diagnosis of coronary artery disease. Am J Cardiol. 1989;64(5):304-10.

[8] Genders TSS, Steyerberg EW, Alkadhi H, Leschka S, Desbiolles L, Nieman K, et al. A clinical prediction rule for the diagnosis of coronary artery disease: validation, updating, and extension. Eur Heart J. 2011;32(11):1316-30.

[9] Chandrasekhar N, Peddakrishna S. Enhancing heart disease prediction accuracy through machine learning techniques and optimization. Processes. 2023;11(4):1210.

[10] Van Calster B, McLernon DJ, van Smeden M, Wynants L, Steyerberg EW. Calibration: the Achilles heel of predictive analytics. BMC Med. 2019;17(1):230.

[11] Collins GS, Reitsma JB, Altman DG, Moons KGM. Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): the TRIPOD statement. BMJ. 2015;350:g7594.

[12] Janosi A, Steinbrunn W, Pfisterer M, Detrano R. Heart Disease [dataset]. UCI Machine Learning Repository; 1988. doi:10.24432/C52P4X.

[13] Riley RD, Ensor J, Snell KIE, Harrell FE Jr, Martin GP, Reitsma JB, et al. Calculating the sample size required for developing a clinical prediction model. BMJ. 2020;368:m441.

[14] Shapiro SS, Wilk MB. An analysis of variance test for normality (complete samples). Biometrika. 1965;52(3-4):591-611.

[15] Hosmer DW, Lemeshow S, Sturdivant RX. Applied logistic regression. 3rd ed. Hoboken (NJ): Wiley; 2013.

[16] Pedregosa F, Varoquaux G, Gramfort A, Michel V, Thirion B, Grisel O, et al. Scikit-learn: machine learning in Python. J Mach Learn Res. 2011;12:2825-30.

[17] Breiman L, Friedman JH, Olshen RA, Stone CJ. Classification and regression trees. Belmont (CA): Wadsworth; 1984.

[18] Breiman L. Random forests. Mach Learn. 2001;45(1):5-32.

[19] Harrell FE Jr. Regression modeling strategies. 2nd ed. Cham: Springer; 2015.

[20] DeLong ER, DeLong DM, Clarke-Pearson DL. Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. Biometrics. 1988;44(3):837-45.

[21] Sun X, Xu W. Fast implementation of DeLong's algorithm for comparing the areas under correlated receiver operating characteristic curves. IEEE Signal Process Lett. 2014;21(11):1389-93.

[22] Nadeau C, Bengio Y. Inference for the generalization error. Mach Learn. 2003;52(3):239-81.

[23] Seabold S, Perktold J. Statsmodels: econometric and statistical modeling with Python. In: Proceedings of the 9th Python in Science Conference; 2010. p. 92-6.

[24] Ministerio de Salud de Colombia. Resolución 8430 de 1993. Bogotá; 1993.

[25] Congreso de la República de Colombia. Ley Estatutaria 1581 de 2012. Bogotá; 2012.